

Le logiciel libre comme méthode de recherche

De l'article scientifique à des milliards d'appareils

Daniel Lemire, professeur
Université du Québec (TÉLUQ)

blogue : <https://lemire.me>

X : [@lemire](#) · GitHub : github.com/lemire

Ce matin, sans le savoir...

2019

PREMIÈRE VERSION

20 k+

ÉTOILES GITHUB

10⁹

APPAREILS

- Vous avez ouvert une page web : **simdutf** a validé son texte.
- Votre application a lu du JSON : **simdjson** l'a analysé.
- Un chiffre est passé de texte à nombre : **fast_float** s'en est chargé.

Node.js, Chrome, Safari, Rust, Go, .NET, ClickHouse... du code écrit dans un laboratoire universitaire, au Québec.

La question

Comment la recherche universitaire finit-elle
dans la poche de milliards de gens ?

D'où viennent les idées ?

“

I never come up with anything by going off to a mountaintop to think. Instead, my ideas come from two sources: talking to real users with real problems and then trying to solve them. This ensures I come up with ideas that somebody cares about and the rubber meets the road and not the sky.

Michael Stonebraker — prix Turing 2014 · Ingres, PostgreSQL, Vertica

Le modèle linéaire de l'innovation

- Le prof réfléchit. Il publie.
- L'ingénieur lit, conçoit.
- Le client consomme.

Vers un vrai modèle de l'innovation

- Révolution industrielle : sous-vêtements.
- Origine du clavier.
- ChatGPT: GPU (jeux), textes (web), chat (Discord).
- Relativité (train)

Partie 1

Le libre comme *méthode* de recherche

“

Le logiciel libre n'est pas seulement une façon de publier des résultats de recherche : c'est une méthode de recherche à part entière.

1. Reproductibilité

- Le code **et** les bancs d'essai sont publics.
- N'importe qui peut relancer la mesure — sur sa machine, avec ses données.
- N'importe qui peut donc **vous réfuter**. C'est le but.

Un gain de performance qui ne survit pas à la machine d'un inconnu n'était pas un résultat.

2. Une évaluation par les pairs bien réelle

COMITÉ DE LECTURE

- 2 à 3 lecteurs
- Ils lisent la description
- Un seul verdict, une seule fois
- Anonyme, sans suite

REVUE DE CODE PUBLIQUE

- Des centaines d'yeux
- Ils exécutent le code
- Un verdict à **chaque** version
- Signé, et il faut y répondre


Les revues de code, les *issues* et les demandes d'intégration sont souvent un arbitrage plus exigeant qu'un comité de lecture.

3. Les données du monde réel viennent à vous

- Des **cas adversariaux** : ça ne fonctionne pas, ça ne suffit pas.
- Des **architectures exotiques** : ARM, POWER, RISC-V, WebAssembly.
- Des **charges réelles** : les fichiers que personne n'aurait pensé à fabriquer.

Partie 2

Une histoire : *simdjson*



Acte 1 — l'analyse du JSON

2019

- Le JSON est partout, et son analyse est **lente** : des centaines de mégaoctets par seconde, au mieux.
- **D'abord le code** : simdjson, écrit avec Geoff Langdale — plusieurs **gigaoctets par seconde**, grâce aux instructions SIMD.
- **Puis un billet de blogue**, GitHub, quelques messages sur X. En quelques jours, des milliers de lecteurs.
- **Puis l'adoption** : bases de données, moteurs analytiques, environnements JavaScript.
- **L'article vient après** : *Parsing Gigabytes of JSON per Second* (VLDB Journal).

L'ordre compte : le logiciel était déjà adopté quand l'article est paru — et l'article n'aurait pas existé sans

Acte 2 — un goulot inattendu : les nombres

RÉVÉLÉ PAR L'USAGE

- Une fois le reste accéléré, l'analyse des **nombres à virgule flottante** devient le goulot.
- Personne n'aurait posé ce problème *a priori* : c'est le profilage d'un vrai analyseur qui l'a désigné.
- Résultat : l'algorithme **Eisel-Lemire**, exact et rapide (*Number Parsing at a Gigabyte per Second*).
- Adoption : Rust, Go, .NET, C++ — les bibliothèques standards elles-mêmes.

Acte 3 — un autre goulot : l'UTF-8

RÉVÉLÉ PAR L'USAGE

- Analyser du JSON, c'est aussi **valider** de l'UTF-8 : la sécurité en dépend.
- Objectif atteint : la validation en **moins d'une instruction par octet**.
- Le morceau s'est détaché pour devenir une bibliothèque à part entière : **simdutf**.
- Adoption : Node.js, Bun, Deno, navigateurs — la validation et la transcodification d'Unicode du web.

Le même cycle, trois fois

PROBLÈME	CODE	ADOPTION	ARTICLE
Analyse JSON	simdjson	bases de données, moteurs JS	VLDB Journal
Analyse des nombres	fast_float	Rust, Go, .NET, C++	Software: P&E
Validation UTF - 8	simdutf	Node.js, Bun, navigateurs	Software: P&E

Chaque ligne est née de la précédente. Aucune n'était au programme de recherche du départ.

Partie 3

Les tensions honnêtes

La maintenance est ingrate

- Le succès se paie en **rapports de bogues**, en demandes de portage, en questions.
- Une faille de sécurité dans votre code, c'est une faille dans Node.js.
- Ce travail est **sans fin** et **invisible** — il ne s'écrit dans aucun CV académique.

Publier un article, c'est terminer. Publier une bibliothèque, c'est commencer.

Les incitatifs sont mal alignés

CE QUE LES COMITÉS COMPTENT

- Les articles
- Les citations
- Les subventions

CE QUI CHANGE LE MONDE

- Les demandes d'intégration
- Les versions maintenues
- Les utilisateurs

Il n'existe pas de case « adopté par un milliard d'appareils » dans un formulaire de promotion.

Ce que je retiens

Le code ouvert **pose** les questions de
recherche,
puis il en **vérifie** les réponses.

Merci

Daniel Lemire · Université du Québec (TÉLUQ)

blogue : <https://lemire.me>

X : [@lemire](#) · GitHub : github.com/lemire

simdjson · fast_float · simdutf · Roaring Bitmaps